1. Binet

Что говорить на польском и что рисовать на доске

Co powiedzieć

Binet to klasyczne mnożenie macierzy zapisane rekurencyjnie. Dzielimy obie macierze na cztery bloki. Każdy blok wyniku jest sumą dwóch iloczynów, więc na jednym poziomie wykonujemy osiem mnożeń rekurencyjnych.

Problemem były nieparzyste rozmiary. Początkowo rozważaliśmy dopisywanie zer do najbliższej potęgi dwójki, ale zwiększałoby to zużycie pamięci i liczbę obliczeń. Dlatego zastosowaliśmy nierówny podział: na przykład pięć dzielimy na dwa i trzy.

Gdy którykolwiek wymiar wynosi jeden, kończymy dzielenie i mnożymy bezpośrednio. Dzięki temu obsługujemy również macierze prostokątne. Złożoność dla macierzy kwadratowych pozostaje sześcienna.

Что рисовать: две матрицы 5×5, разрез после второй строки и колонки

A11 2×2	**A12** 2×3
A21 3×2	**A22** 3×3

B11 2×2	**B12** 2×3
B21 3×2	**B22** 3×3

C11 = A11·B11 + A12·B21

(2×2)·(2×2) + (2×3)·(3×2) = (2×2) + (2×2)

Co powiedzieć przy rysunku

Bloki nie muszą być równe. Ważne, żeby wymiary mnożenia pasowały, a oba wyniki miały ten sam rozmiar. Tutaj oba iloczyny dają blok dwa na dwa, więc możemy je dodać. Pozostałe trzy bloki wyniku liczymy analogicznie.

Для себя

Для умножения совпадают внутренние размеры: (r×k)·(k×s) → r×s. Для сложения совпадает весь размер. Поэтому колонки A и строки B делим в одном месте. Пример с памятью: дополнение 5×5 до 8×8 увеличивает буфер с 25 до 64 элементов.

2. Strassen

Чётный размер: равные блоки. Нечётный: отделяем край.

Co powiedzieć

Strassen działa podobnie do Bineta, ale zamiast ośmiu mnożeń rekurencyjnych wykonuje siedem. W zamian potrzebuje więcej dodawań i odejmowań. Dzięki temu złożoność spada z n do trzeciej do około n do potęgi 2,81.

Dla parzystego rozmiaru dzielimy macierze na cztery równe bloki. Tutaj bloki muszą mieć jednakowe rozmiary, ponieważ dodajemy je do siebie przed mnożeniem.

Dla nieparzystego rozmiaru oddzielamy ostatni wiersz i kolumnę. Główną część mnożymy Strassenem, a iloczyny z udziałem wydzielonych części liczymy zwykłym mnożeniem. Na końcu składamy wynik. Dzięki temu nie musimy dopisywać zer.

Сначала: матрица 4×4, четыре блока 2×2

P1 = (A11 + A22)·(B11 + B22)
Takich iloczynów jest siedem. Z ich sum i różnic odtwarzamy cztery bloki wyniku.

Затем: две матрицы 5×5, отделяем последнюю строку и колонку

A0 4×4	**a** 4×1
r 1×4	**α** 1×1

B0 4×4	**b** 4×1
s 1×4	**β** 1×1

C11 = Strassen(A0, B0) + a·s
C12 = A0·b + a·β
C21 = r·B0 + α·s
C22 = r·b + α·β

При рисунке: Tylko iloczyn A zero razy B zero liczymy tutaj Strassenem. Pozostałe iloczyny liczymy bezpośrednio. Niczego nie odrzucamy - ostatni wiersz i kolumna też wchodzą do wyniku.

Для себя: a·s: столбец × строка → матрица 4×4. r·b: строка × столбец → число. Наш Страссен поддерживает только квадратные матрицы. Правило повторяется на каждом уровне; для n = 1 считаем одно произведение.

3. AlphaTensor

Готовые коэффициенты, 76 произведений и дополнение нулями

Co powiedzieć

W trzeciej metodzie wykorzystaliśmy gotowy algorytm odkryty przez AlphaTensor. Nie trenowaliśmy modelu - korzystamy z opublikowanych współczynników.

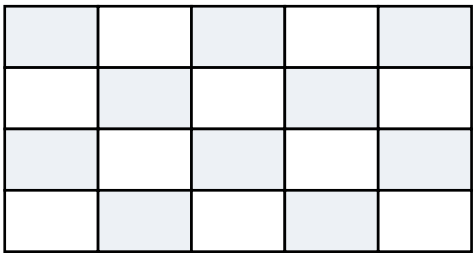
Macierz A dzielimy na siatkę cztery na pięć bloków, a B na pięć na pięć. Tworzymy odpowiednie sumy i różnice bloków, dzięki którym wykonujemy 76 mnożeń rekurencyjnych zamiast stu. Następnie składamy z nich wynik.

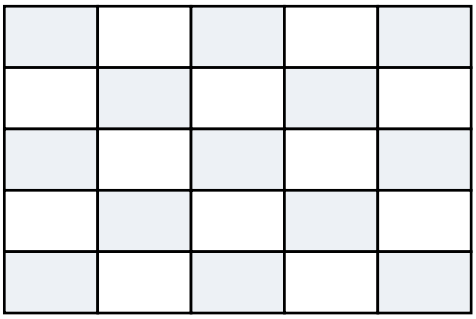
Problemem były dowolne rozmiary macierzy. Dopisujemy zera do wymaganych wielokrotności, a po obliczeniu przycinamy wynik. Dla małych bloków przechodzimy do zwykłego mnożenia.

Musieliśmy też dopasować kolejność współczynników wyjściowych, bo dane źródłowe używały transponowanego indeksowania. Poprawność sprawdziliśmy na wszystkich 500 parach macierzy bazowych.

Dopełnianie zerami i kombinacje bloków zwiększały koszt, więc 76 mnożeń zamiast stu nie zawsze dawało krótszy czas.

Что рисовать: A - сетка 4×5, B - сетка 5×5





100 произведений → 76 произведений

Комбинации блоков → рекурсивные произведения → сборка результата.

Для себя: как работают размеры и коэффициенты

4×5 и 5×5 - количество блоков, а не обязательный размер исходных матриц. Сами блоки могут быть большими матрицами.

Строки A дополняем до ближайшего кратного 4. Колонки A, строки B и колонки B - до кратного 5. Например: A 7×11 → 8×15; B 11×9 → 15×10. После вычислений берём из результата только исходные 7×9.

Если строк A меньше 4, общий размер меньше 5 или колонок B меньше 5 - обычное умножение. В остальных случаях снова делим и используем 76 произведений.

Пара коэффициентов (номер блока, знак) задаёт слагаемое. Например, [(0, −1), (5, 1), (8, −1)] означает −block[0] + block[5] − block[8]. Эти списки описывают, какие блоки сложить и вычесть.